

Universidad Autónoma de Baja California

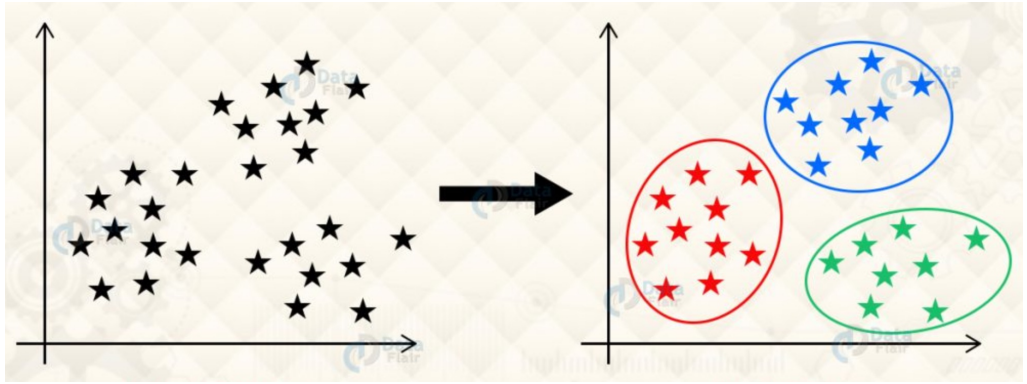
Maestría y Doctorado en Ciencias e Ingeniería
Ing. en Computación / Ing. en Software y Tecnologías Emergentes

4. Agrupación

Ciencia de los Datos

¿Qué es agrupación o mejor dicho el análisis de grupos?

- *Es el proceso de agrupar un conjunto de datos hacia múltiples grupos (clusters) tal que esos objetos dentro un mismo grupo tiene alta similitud, pero son muy disimilares de otros grupos. Las disimilitudes y similitudes son validadas en base en los valores de los atributos que describen a los objetos y frecuentemente involucran medidas de distancias.*



Análisis de grupos

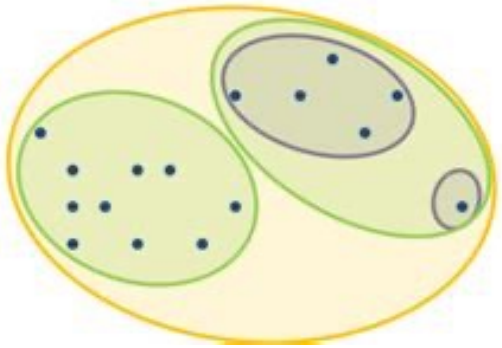
- *Agrupación es el proceso de particionar un conjunto de objetos de datos hacia subconjuntos. Donde cada subconjunto es un grupo, tal que los objetos dentro un grupo son similares el uno al otro, y disimilares con los objetos de otros grupos. Bajo este contexto, diferentes métodos de agrupación pueden generar diferentes grupos a partir del mismo conjunto de datos.*
- *La agrupación es útil en el hecho de que puede llevar al descubrimiento de grupos desconocidos dentro de los datos.*
- *En anális de grupos es conocido como aprendizaje no supervisado porque las etiquetas de clases no estan presentes. Por esta razón, agrupación es una manera de aprender a partir de observación, en lugar de aprendizaje mediante ejemplos (aprendizaje supervisado).*

Clasificación de técnicas de agrupación

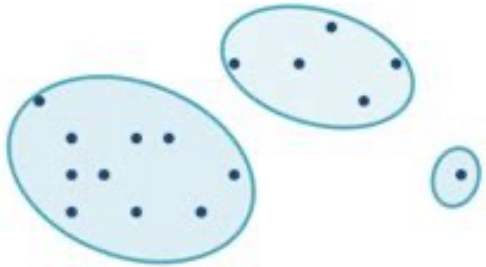
Method	General Characteristics
Partitioning methods	– Find mutually exclusive clusters of spherical shape – Distance-based – May use mean or medoid (etc.) to represent cluster center – Effective for small- to medium-size data sets
Hierarchical methods	– Clustering is a hierarchical decomposition (i.e., multiple levels) – Cannot correct erroneous merges or splits – May incorporate other techniques like microclustering or consider object "linkages"
Density-based methods	– Can find arbitrarily shaped clusters – Clusters are dense regions of objects in space that are separated by low-density regions – Cluster density: Each point must have a minimum number of points within its "neighborhood" – May filter out outliers
Grid-based methods	– Use a multiresolution grid data structure – Fast processing time (typically independent of the number of data objects, yet dependent on grid size)

Ejemplos de las clasificaciones de técnicas de agrupación

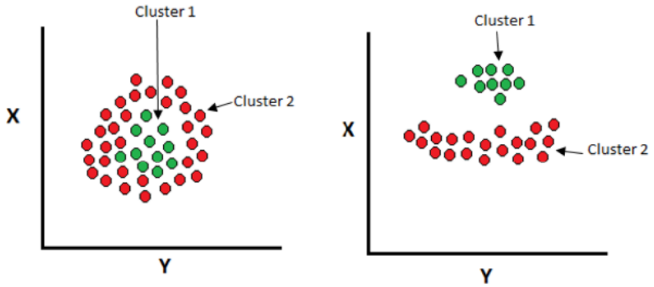
Hierarchical-based Clustering



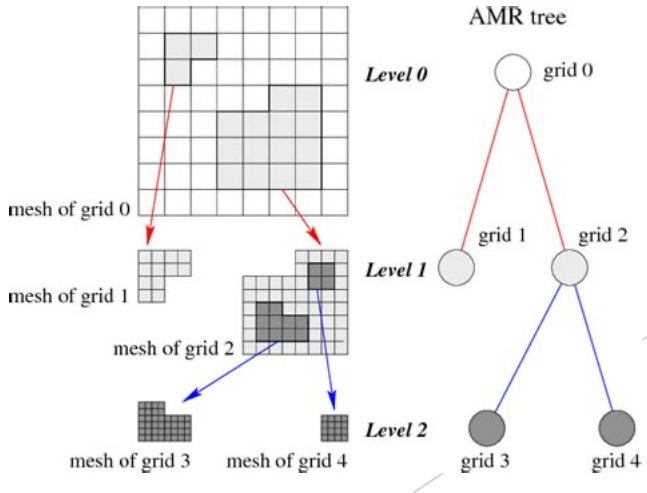
Partitioning-based Clustering



Density-based Clustering



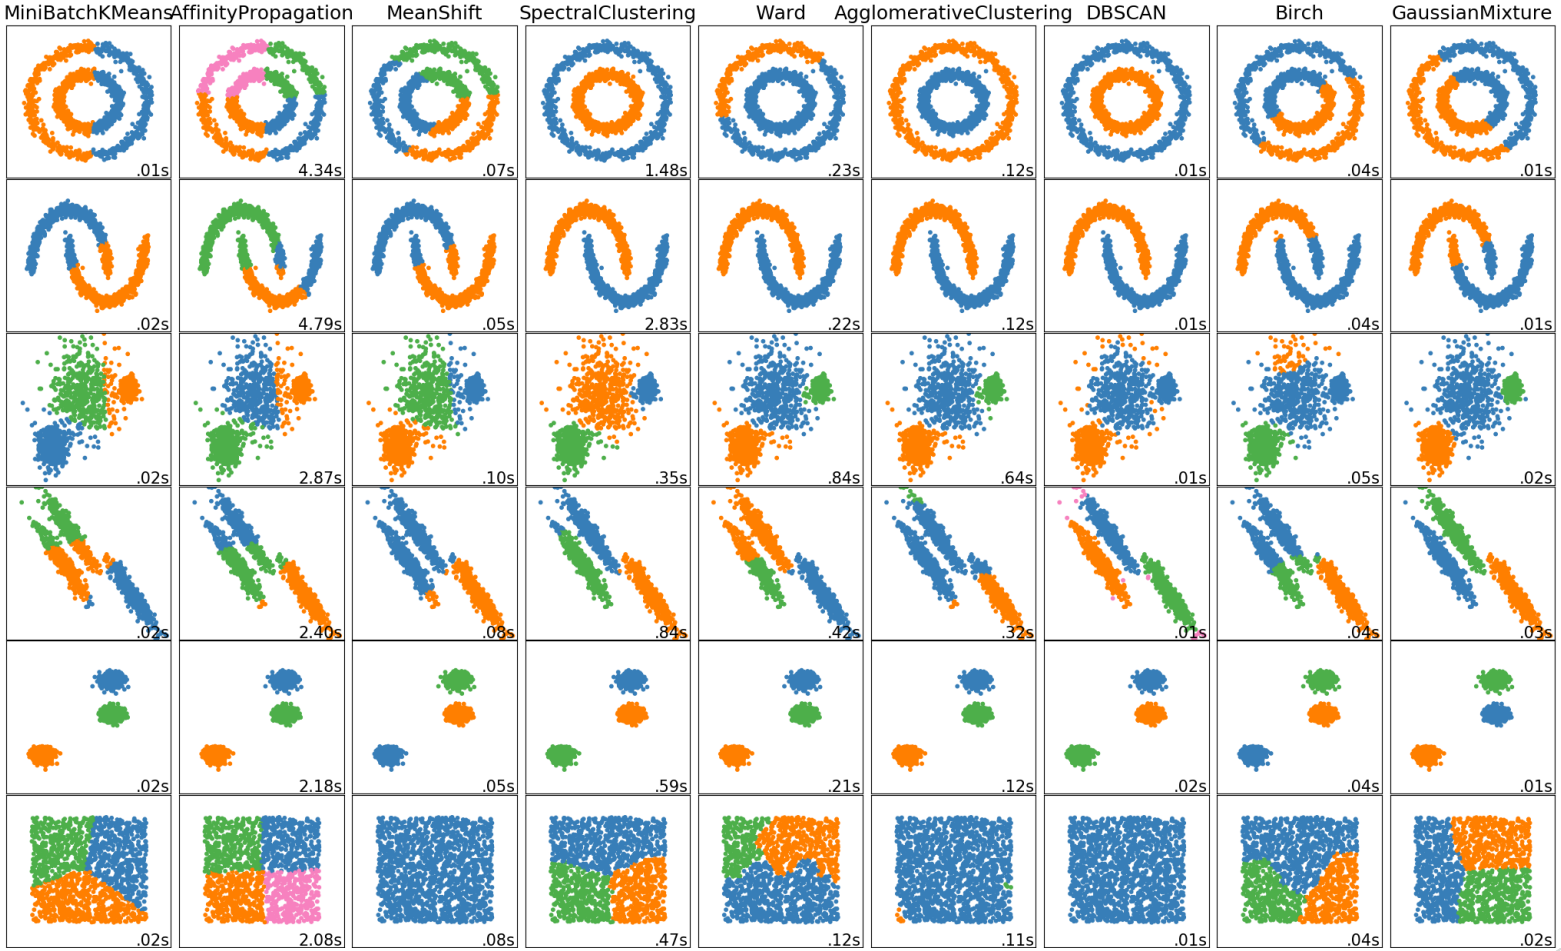
Grid-based Clustering



Ejemplos de tipos de algoritmos existentes

- *Métodos basados en partición*
  - *K-Means*
  - *K-Medoids*
- *Métodos jerárquicos*
  - *BIRCH*
  - *Jerárquico probabilístico*
- *Métodos basados en densidad*
  - *DBSCAN*
  - *OPTICS*
  - *DENCLUE*
- *Métodos basados en grid*
  - *STING*
  - *CLIQUE*

Ejemplos de tipos de algoritmos existentes



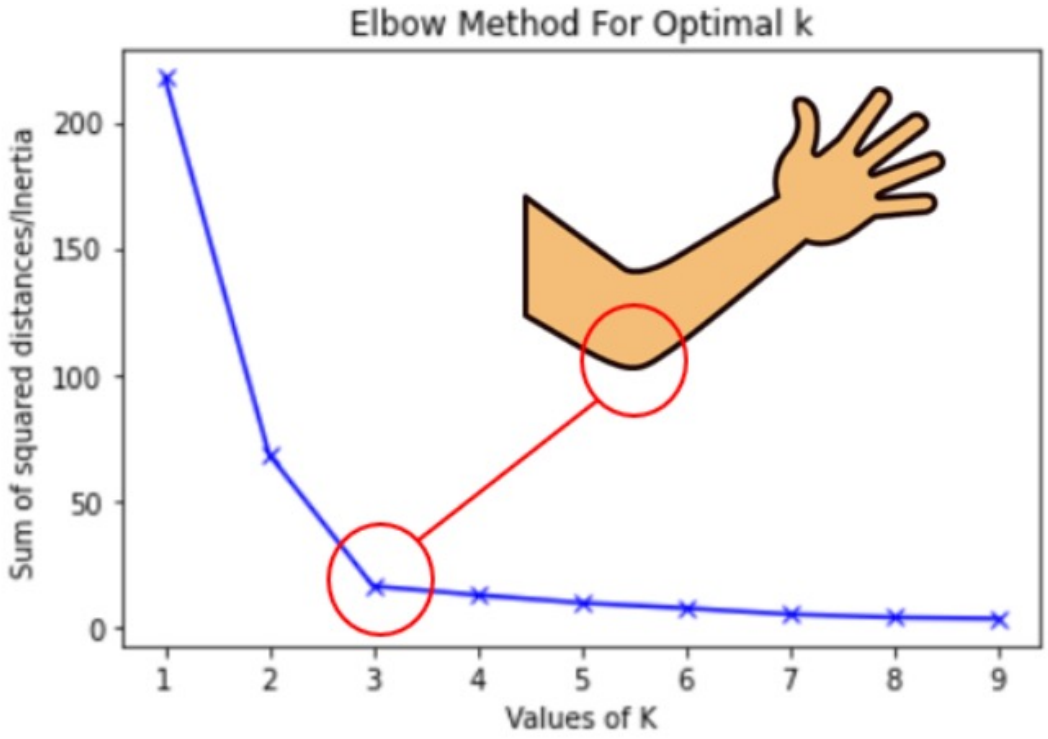
Evaluación de la agrupación

- *Las principales tareas en la evaluación de las agrupaciones incluyen lo siguiente:*
  - ***Evaluación de la tendencia de los grupos**. La tarea de agrupación sólo es significativa si no existen datos aleatorios en la estructura.*
  - ***Determinación del número de grupos en un conjunto de datos**. Es importante previo al proceso de agrupación tener un estimado estadístico de la cantidad de grupos que se desea y pueden encontrar.*
  - ***Medición de la calidad de la agrupación**. Hay varias técnicas para evaluar la calidad de los grupos encontrados.*

Determinación el número de grupos en un conjunto de datos

- *Un método simple para identificar un número inicial de grupos es mediante para un conjunto de datos con n puntos.* $\sqrt{\frac{n}{2}}$
- *El método del codo, realiza una búsqueda de $K>0<K^{max}$ mediante el cual la suma de todas las varianzas dentro del grupo var(K), y posteriormente se grafica el comportamiento de K/var(K) y donde haya un cambio pronunciado se asume es el K óptimo.*
  - *Este es natural para el Kmeans, aunque puede usarse un tipo de parchazo con otras técnicas, solamente hay que identificar un índice que tenga un comportamiento similar que la técnica pueda darte o ser calculada*
- *Otros.*

Método del codo



Line plot between K and inertia

Medición de la calidad de la agrupación

- *Hay dos categorías de éstas medidas de calidad:*
  - ***Extrínsecas**. Si el ground truth está disponible, se pueden comparar los grupos contra los grupos verdaderos y medir.*
    - *Se usan para validar técnicas de agrupación y los datos provienen de datasets de clasificación donde las etiquetas son conocidas.*
  - ***Intrínsecas**. Si el ground truth no está disponible, se usan éstos métodos donde se evalúan que tan bien se realizó la agrupación considerando que tan bien los grupos están separados.*
    - *Se usan cuando se tiene la intención real de agrupar para analizar los datos.*

Métodos extrínsecos

- ***Cluster homogeneity**. Esto requiere que entre más puros sean los grupos, mejor será la agrupación.*
- ***Cluster completeness**. Es la contraparte del anterior. Requiere que una agrupación, si cualquiera de dos objetos pertenecen a la misma categoría de acuerdo al ground truth, entonces estos deberían ser asignados al mismo grupo. Esto es, la agrupación debería asignar objetos pertenecientes a la misma categoría (de acuerdo al *ground truth*) al mismo grupo.*
- ***Rag bag**. En muchos escenarios, la categoría *rag bag* contiene objetos que no puedes unificarse con otros objetos. Este criterio establece que poner un objeto heterogéneo dentro de un grupo puro debe de ser penalizado más que el ponerlo dentro de un *rag bag*.*
- ***Small cluster preservation**. Si una categoría se parte en pequeños pedazos durante una agrupación, esos pedazos pequeños pudieran volverse ruido y por lo tanto la pequeña categoría no pudiera ser encontrada durante la agrupación. Este criterio establece que partir una categoría pequeña en pedazos es más dañino que partir una categoría grande en pedazos.*
- **The Rand Index** evaluates the similarity between the true cluster labels and the predicted cluster labels. The index ranges from 0 to 1, with 1 indicating a perfect match between the true and predicted labels. The Rand Index is often used in image segmentation, text clustering, and document clustering, where the true labels of the data are known.
- The **Fowlkes-Mallows index** is named after two researchers, Edward Fowlkes and S.G. Mallows, who proposed the metric in 1983. The index measures the similarity between a clustering algorithm's true and predicted labels. The score ranges from 0 to 1, with 1 indicating a perfect match between the true and predicted labels. The Fowlkes-Mallows score is often used in image segmentation, text clustering, and document clustering, where the true labels of the data are known.

Métodos extrínsecos

- *Varias medidas de calidad de agrupación satisfacen los cuatro criterios anteriormente mencionados. Tal como las métricas Bcubed, precision y recall.*
  - *Bcubed, evalua la precision y recall por cada objeto dentro de una agrupación en un dado conjunto de datos acorde al ground truth.*
  - *La precisión, de un objeto indica que tantos objetos dentro del mismo grupo pertenecen a la misma categoría que el objeto.*
  - *El recall, de un objeto refleja que tantos objetos de la misma categoría son asignados al mismo grupo.*

Métodos intrínsecos

- *En general, estos métodos evaluan la agrupación mediante la examinación de que tan bien los grupos se encuentran separados y que tan compactos los grupos estan.*
- *The **Silhouette Coefficient** measures the quality of clustering based on how well-separated the clusters are and how similar are the data points within each cluster. The coefficient ranges from -1 to 1, with 1 indicating a well-separated and compact cluster and -1 indicating an incorrect clustering.*
- *The **Davies-Bouldin Index** is named after two researchers, David L. Davies and Donald W. Bouldin, who proposed the metric in 1979. The index ranges from 0 to infinity, with lower values indicating better clustering quality. It is handy for identifying the optimal number of clusters in the data and for detecting cases where the clusters overlap or are too similar to each other. However, the index assumes that the clusters are spherical and have similar densities, which may not always hold in real-world datasets.*
- *The **Calinski-Harabasz Index** is named after T. Calinski and J. Harabasz, who proposed the metric in 1974. The Calinski-Harabasz Index measures the quality of clustering based on how well-separated the clusters are and how well the data points within each cluster are similar to each other. The index ranges from 0 to infinity, with higher values indicating better clustering.*

Actividad para licenciatura

- *Conseguir 1 dataset de agrupación + 1 dataset de clasificación (dataset del Iris)*
- *Usar 4 técnicas diferentes para agrupar (de clasificación diferente: partición, densidad, jerárquico, y cuadricula)*
- *Utilizar mínimo 3 técnicas intrínsecas y 1 extrínseca, dependiendo del caso, para determinar la calidad de los grupos*
  - *Para el caso del dataset de clasificación, para usarlo como dataset de agrupación hay eliminar las etiquetas pero usarlas como el ground truth (extrínsecas)*
- *De los experimentos realizados, exponer:*
  - *Cómo funcionan las técnicas elegidas*
    - *Superficialmente entender los procesos de agrupación*
    - *Describir cómo se recomienda eligir los parámetros de la técnica*
  - *Explicar qué buscan los indices de validación que eligieron y cómo interpretarlos*
  - *Identificar cuál algoritmo fue mejor para resolver cada dataset*

Actividad para posgrado

- *Conseguir 1 dataset de agrupación + 1 dataset de clasificación (dataset del Iris)*
- *Usar 4 técnicas diferentes para agrupar (de clasificación diferente: partición, densidad, jerárquico, y cuadricula)*
- *Utilizar mínimo 3 técnicas intrínsecas y 1 extrínseca, dependiendo del caso, para determinar la calidad de los grupos*
  - *Para el caso del dataset de clasificación, para usarlo como dataset de agrupación hay eliminar las etiquetas pero usarlas como el ground truth (extrínsecas)*
- *De los experimentos realizados, exponer:*
  - *Cómo funcionan las técnicas elegidas*
    - *Algoritmicamente*
    - *Describir cómo se recomienda eligir los parámetros de la técnica*
  - *Explicar qué buscan los indices de validación que eligieron y cómo interpretarlos*
  - *Identificar cuál algoritmo fue mejor para resolver cada dataset*
  - *Interpretación de los resultados obtenidos. Aplicar un EDA para describir los grupos*